

机器学习大作业实验报告

Back to Basics: Let Denoising Generative
Models Denoise

JiT 模型复现与改进实验

课程名称：机器学习

学院：武汉大学计算机学院

专业班级：计算机科学与技术（雷军班）

小组成员：杜承敖、肖昌珅、金奕辰、全坤

指导教师：武宇

完成日期：2026 年 7 月 6 日

摘要

扩散生成模型最初以“去噪”为核心思想，但主流实现通常预测噪声或速度场，而不是直接预测干净图像。Li 和 He 提出的 JiT (Just image Transformer) 重新强调在 flow matching 框架下直接预测干净图像，并证明简洁的大 patch Vision Transformer 可以在像素空间取得有竞争力的生成效果。本报告围绕该论文完成 JiT-B/16 的复现与轻量改进实验。我们首先复现了模型结构、flow matching 训练目标、Euler/Heun 采样流程和 classifier-free guidance 机制，并基于 ImageNet-1K 子集进行 20 epoch fine-tuning。随后，我们提出并验证了两类改进：其一是结构化噪声过程 SNP，在训练端引入区域化噪声强度以提升生成多样性；其二是时间条件采样加速 TCTM，在高噪声阶段采用 step skipping 以降低采样耗时。实验结果显示，baseline fine-tuning 能稳定收敛，最终 flow loss 为 0.0518， x_0 MSE 为 0.0247；SNP 将像素多样性指标从 58.3 提升到 63.9，提升约 9.6%；推荐 TCTM 配置在本轮实验中达到 1.93 倍采样加速，但伴随一定多样性下降。最后，报告分析了当前实验的局限性，包括数据规模较小、指标仍为轻量 proxy、TCTM 尚非真正 token merging 以及缺少多 seed 评估等问题，并给出后续改进方向。

关键词：扩散模型；Flow Matching；JiT；结构化噪声；采样加速

目录

1	引言	3
2	实验任务与数据集	3
2.1	实验任务	3
2.2	数据集来源	3
2.3	数据预处理	4
3	方法原理	4
3.1	Flow Matching 与 x_0 预测	4
3.2	JiT-B/16 模型结构	5
3.3	采样方法	6
4	实验设计	7
4.1	实验环境	7
4.2	参数设置	7
4.3	评价指标	7
5	Baseline 复现结果与分析	8
6	改进算法与消融实验	9
6.1	SNP 结构化噪声过程	9
6.2	TCTM 时间条件采样加速	10
7	综合结果与讨论	12
8	小组分工	14
9	局限性与后续工作	14
10	总结	15
A	附录 A 复现实验命令	17
B	附录 B 关键超参数	17

1 引言

扩散生成模型通过逐步从噪声恢复数据来完成生成任务。早期扩散模型的直观目标是“去噪”，即从被破坏的样本预测干净图像。然而在实际发展中，DDPM 等方法常采用噪声预测，后续 flow matching 和 rectified flow 类方法又常采用速度预测。原论文《Back to Basics: Let Denoising Generative Models Denoise》指出，在高维像素空间中，干净自然图像可视为位于低维流形上，而噪声和速度等被污染量分布在更高维空间中。因此，当模型容量有限时，让网络直接预测干净图像 x_0 可能比预测噪声或速度更符合流形假设，也更适合像素空间 Transformer。

JiT 的目标是回到这一基础假设：使用普通 Vision Transformer 直接处理图像 patch 序列，并在 flow matching 框架下直接输出干净图像预测。它不依赖 VAE tokenizer、感知损失、对抗损失或自监督表征对齐，而是以大 patch、bottleneck patch embedding、通用 Transformer 改进和 x_0 prediction 形成自包含的像素空间生成模型。

本项目的任务是复现 JiT 的关键结构和训练采样流程，并在此基础上探索轻量改进。考虑课程大作业的算力限制，我们没有完整重训 ImageNet-1K，而是使用官方预训练权重和 ImageNet 子集进行快速验证。报告重点不在宣称达到原文完整 FID，而在说明复现链路是否正确、训练是否稳定，以及提出的改进方法是否在轻量指标上呈现合理趋势。

2 实验任务与数据集

2.1 实验任务

本实验围绕类条件图像生成展开，主要任务包括：

1. 复现 JiT-B/16 的模型结构，包括 bottleneck patch embedding、Transformer blocks、RoPE、adaLN-Zero 和 in-context class tokens。
2. 复现 flow matching 训练目标，完成 z_t 构造、 x_0 prediction、velocity loss 和 EMA 维护。
3. 复现 Euler/Heun ODE 采样过程，并支持 classifier-free guidance。
4. 在 baseline 复现基础上实现两类改进：SNP 结构化噪声过程和 TCTM 时间条件采样加速。
5. 使用训练损失、 x_0 MSE、采样耗时、像素多样性和图像对比度等指标分析实验结果。

2.2 数据集来源

原论文在 ImageNet-1K 上进行系统实验。受限于课程实验资源，本项目使用 ImageNet-1K 的轻量子集进行快速验证，默认每类采样约 2 张图像，共约 2000 张图像。数据组织方式保持 ImageFolder 格式：

Listing 1 ImageNet 子集目录结构示例

```

1 data/imagenet_2000/
2   train/
3     n01440764/*.JPEG
4     n01443537/*.JPEG
5     ...
6   val/
7     n01440764/*.JPEG
8     n01443537/*.JPEG
9     ...

```

2.3 数据预处理

训练脚本使用与参考实现接近的预处理：先对输入图像做中心裁剪并缩放到 256×256 ，然后进行随机水平翻转和张量化。训练前将像素从 $[0, 255]$ 归一化到 $[-1, 1]$ 。这一处理方式与生成阶段的反归一化相对应，生成图像最终再映射回 $[0, 255]$ 保存。

3 方法原理

3.1 Flow Matching 与 x_0 预测

设干净图像为 $\mathbf{x} \sim p_{\text{data}}(\mathbf{x})$ ，噪声为 $\boldsymbol{\epsilon} \sim \mathcal{N}(0, \mathbf{I})$ ，时间步 $t \in [0, 1]$ 。JiT 采用线性插值形式构造 noisy sample:

$$\mathbf{z}_t = t\mathbf{x} + (1-t)\boldsymbol{\epsilon}. \quad (1)$$

当 $t = 0$ 时， $\mathbf{z}_t$ 接近纯噪声；当 $t = 1$ 时， $\mathbf{z}_t$ 接近干净图像。由式 (1) 可得 flow velocity:

$$\mathbf{v} = \frac{d\mathbf{z}_t}{dt} = \mathbf{x} - \boldsymbol{\epsilon}. \quad (2)$$

JiT 的核心选择是让网络直接输出干净图像预测:

$$\mathbf{x}_\theta = \text{net}_\theta(\mathbf{z}_t, t, y), \quad (3)$$

其中 y 是类别条件。由于采样需要速度场，可由 $\mathbf{x}_\theta$ 推出预测速度:

$$\mathbf{v}_\theta(\mathbf{z}_t, t, y) = \frac{\mathbf{x}_\theta - \mathbf{z}_t}{1-t}. \quad (4)$$

训练损失采用 velocity MSE:

$$\mathcal{L}_{\text{flow}} = \mathbb{E}_{t, \mathbf{x}, \boldsymbol{\epsilon}} \|\mathbf{v}_\theta(\mathbf{z}_t, t, y) - \mathbf{v}\|_2^2. \quad (5)$$

从等价变换看，该损失相当于对 x_0 预测误差进行时间相关加权:

$$\mathcal{L}_{\text{flow}} = \mathbb{E}_{t, \mathbf{x}, \epsilon} \frac{1}{(1-t)^2} \|\mathbf{x}_\theta(\mathbf{z}_t, t, y) - \mathbf{x}\|_2^2. \quad (6)$$

因此，JiT 既保留了 flow matching 的 ODE 采样形式，又让网络直接学习回到干净图像流形的映射。

3.2 JiT-B/16 模型结构

JiT 将输入图像划分为非重叠 patch，并使用 Transformer 直接处理 patch token。图 1 展示了原论文中的 JiT 架构示意。复现版本采用 JiT-B/16，输入分辨率为 256×256 ，patch size 为 16，因此序列长度为 $16 \times 16 = 256$ 。




图 1 JiT 架构示意图。模型直接在像素 patch 上使用 Transformer，并输出 x_0 prediction。

本项目复现的主要结构配置如表 1 所示。

表 1 JiT-B/16 复现模型结构配置

配置项	取值
输入分辨率	256×256
Patch size	16
Token 数量	256
Hidden size	768
Transformer depth	12
Attention heads	12
Bottleneck dim	128
In-context class tokens	32
In-context 插入层	第 4 层
参数量	约 130M

与原始 ViT 相比, JiT 在生成任务中加入了若干通用改进: 第一, patch embedding 使用 bottleneck 设计, 即先将每个 patch 映射到较低维表示, 再扩展到 Transformer hidden size; 第二, 注意力使用 RoPE 和 qk-norm; 第三, 前馈网络采用 SwiGLU; 第四, 条件信息通过时间嵌入、类别嵌入和 adaLN-Zero 注入模型; 第五, 在中间层插入多个类别上下文 token, 以增强类条件建模能力。

3.3 采样方法

生成阶段从高斯噪声 $\mathbf{z}_0$ 出发, 求解如下 ODE:

$$\frac{d\mathbf{z}_t}{dt} = \mathbf{v}_\theta(\mathbf{z}_t, t, y). \quad (7)$$

复现代码支持 Euler 和 Heun 两种求解器。Euler 方法使用当前速度进行一步更新:

$$\mathbf{z}_{t+\Delta t} = \mathbf{z}_t + \Delta t \cdot \mathbf{v}_\theta(\mathbf{z}_t, t, y). \quad (8)$$

Heun 方法先进行一次 Euler 预测, 再在下一时间点重新估计速度并取平均, 通常比 Euler 更稳定。本项目默认使用 50 步 Heun 采样。

对于类条件生成, 复现代码实现了 classifier-free guidance。给定条件预测速度 $\mathbf{v}_{\text{cond}}$ 和无条件预测速度 $\mathbf{v}_{\text{uncond}}$, 最终速度为:

$$\mathbf{v}_{\text{cfg}} = \mathbf{v}_{\text{uncond}} + s(\mathbf{v}_{\text{cond}} - \mathbf{v}_{\text{uncond}}), \quad (9)$$

其中 s 为 guidance scale。

4 实验设计

4.1 实验环境

实验环境与工程设置如表 2 所示。由于不同机器上的 GPU 与依赖版本可能不同，表中重点列出复现实验代码固定的关键配置。

表 2 实验环境与工程配置

项目	配置
编程语言	Python
深度学习框架	PyTorch
主要依赖	torchvision、torch-fidelity、tensorboard、opencv-python
训练脚本	scripts/train.py
Baseline 脚本	scripts/01_train_baseline.sh
SNP 脚本	scripts/02_train_snp.sh
TCTM 脚本	scripts/03_train_tctm.sh
随机种子	42

4.2 参数设置

训练与采样参数见表 3。本实验使用官方或已转换的预训练 JiT-B/16 权重作为初始化，并在 ImageNet 子集上 fine-tuning。

表 3 主要训练与采样参数

参数	取值
模型	JiT-B/16
图像分辨率	256×256
数据集规模	约 2000 张图像
Fine-tuning epochs	20
Batch size	32
Base learning rate	5.0×10^{-5}
实际 learning rate	6.25×10^{-6}
Optimizer	AdamW
AdamW betas	(0.9, 0.95)
时间步分布	logit-normal, $P_{\text{mean}} = -0.8$, $P_{\text{std}} = 0.8$
采样器	Heun
采样步数	50

4.3 评价指标

由于完整 FID-50K 需要大量生成样本和标准统计文件，本轮课程实验采用轻量 proxy 指标分析趋势：

- Flow matching loss: 衡量 velocity 预测误差，是训练主损失。
- x_0 MSE: 衡量网络输出干净图像预测与真实图像之间的均方误差。
- 采样时间: 衡量不同采样策略下的推理速度。
- 像素多样性 σ : 统计生成样本像素分布标准差，用于粗略反映多样性。
- 图像对比度: 以图像动态范围 proxy 衡量视觉对比度。
- 均值稳定性: 观察加速采样是否导致整体像素分布发生明显偏移。

需要强调的是，这些指标不能替代完整 ImageNet FID、IS 和 precision/recall，只能用于课程复现实验中的方法趋势比较。

5 Baseline 复现结果与分析

Baseline 使用 pretrained JiT-B/16 初始化，在 ImageNet 子集上 fine-tuning 20 epochs。训练曲线如图 2 所示。




图 2 Baseline 与 SNP 的训练收敛曲线。左图为 flow matching loss，右图为 x_0 MSE。

由图 2 可见，baseline 的 flow loss 在训练过程中存在一定波动，但总体保持稳定下降趋势，未出现发散。20 epoch 后 baseline 的 final flow loss 为 0.0518，final x_0 MSE 为 0.0247。表 4 汇总了 baseline 复现实验的主要结果。

表 4 Baseline 复现实验结果

指标	数值
Final flow loss	0.0518
Final x_0 MSE	0.0247
Baseline 采样时间	2.03 s
TCTM 对比中的像素多样性 σ	56.4
TCTM 对比中的采样均值	103.9
SNP 对比中的像素多样性 σ	58.3
SNP 对比中的图像对比度	251.2

这些结果说明，本项目复现的训练、采样和日志链路能够正常工作。受数据规模限制，baseline 的数值不能与原论文完整 ImageNet 结果直接比较，但可以作为后续 SNP 和 TCTM 改进的内部对照。

6 改进算法与消融实验

6.1 SNP 结构化噪声过程

标准 flow matching 在训练时使用全图均匀强度的高斯噪声。我们认为自然图像的退化并不一定在空间上均匀，若训练阶段能让模型看到局部保留结构、局部强噪声的样本，模型可能学习到更鲁棒的局部恢复能力。基于这一动机，本项目实现了 SNP (Structured Noise Process) 结构化噪声过程。

SNP 对每张图像随机采样 1 到 3 个矩形区域，矩形边长在 32 到 128 像素之间。区域内使用较低噪声强度 $\sigma_{\text{in}} = 0.5$ ，区域外使用正常噪声强度 $\sigma_{\text{out}} = 1.0$ 。设随机噪声为 ϵ ，空间噪声强度图为 M ，则结构化噪声可写为：

$$\epsilon_{\text{snp}} = M \odot \epsilon, \quad (10)$$

其中

$$M_{i,j} = \begin{cases} \sigma_{\text{in}}, & (i,j) \in \text{rectangles}, \\ \sigma_{\text{out}}, & \text{otherwise.} \end{cases} \quad (11)$$

随后仍按式 (1) 构造 noisy sample:

$$\mathbf{z}_t = t\mathbf{x} + (1-t)\epsilon_{\text{snp}}. \quad (12)$$

SNP 不改变模型结构，也不改变采样过程，只替换训练时的 noise process。其核心伪代码如下：

Listing 2 SNP 结构化噪声核心逻辑

```

1 def structured_noise(x):
2     e = randn_like(x)
3     noise_map = full_like(x[:, :1], sigma_out)
4     for each image in batch:
5         n_rects = randint(1, 3)
6         for k in range(n_rects):
7             rect = sample_rectangle(size_min=32, size_max=128)
8             noise_map[rect] = sigma_in
9     return e * noise_map

```

SNP 实验结果如图 3 和表 5 所示。




图 3 SNP 与 baseline 在像素多样性和图像对比度上的对比。

表 5 SNP 与 baseline fine-tuning 结果对比

指标	Baseline FT	SNP FT	变化
Final flow loss	0.0518	0.0481	更低
Final x_0 MSE	0.0247	0.0259	接近
像素多样性 σ	58.3	63.9	+9.6%
图像对比度	251.2	253.4	+0.9%

由表 5 可知，SNP 的主要收益体现在生成样本统计多样性上。像素多样性从 58.3 提升到 63.9，提升约 9.6%；图像对比度也有轻微提升。 x_0 MSE 与 baseline 接近，说明结构化噪声没有明显破坏干净图像预测能力。结合图 2，SNP 的训练曲线在早期下降更快，后期与 baseline 保持接近。

6.2 TCTM 时间条件采样加速

JiT 的高质量生成通常使用 50 步 Heun 采样。观察采样轨迹可知，高噪声阶段图像细节尚未形成，速度场变化相对粗粒度；低噪声阶段接近干净图像，细节恢复对步长更敏感。因此，本项目实现 TCTM (Time-Conditioned Sampling Acceleration) 用于采样端加速。

需要说明的是，PPT 与脚本沿用了 TCTM (Time-Conditioned Token Merging) 的名称，但当前仓库实现本质上是时间条件 ODE step skipping，而不是真正的 ToMe-style token merging。其逻辑为：当 t 小于阈值 τ 时，以更大的步长跳过若干中间时间点；当 $t \geq \tau$ 时，仍使用正常步长。设跳步倍率为 k ，则下一步索引为：

$$i_{\text{next}} = \begin{cases} \min(i + k, N - 1), & t_i < \tau, \\ i + 1, & t_i \geq \tau. \end{cases} \quad (13)$$

TCTM 伪代码如下：

Listing 3 TCTM step skipping 采样逻辑

```

1  i = 0
2  while i < num_steps - 1:
3      t = timesteps[i]
4      if tctm_enable and t < threshold:
5          skip = max(1, int(1.0 / merge_ratio))
6          next_i = min(i + skip, num_steps - 1)
7      else:
8          next_i = i + 1
9      z = heun_step(model, z, timesteps[i], timesteps[next_i], labels)
10     i = next_i
11 z = euler_step(model, z, timesteps[-2], timesteps[-1], labels)

```

TCTM 的速度-质量 Pareto 结果如图 4 所示，阈值与跳步因子的 sweep 结果如图 5 所示。




图 4 TCTM 速度-质量折中。横轴为采样加速比，纵轴为像素多样性 σ 。




图 5 不同阈值与跳步因子下的 TCTM 采样加速比。

量化结果如表 6 所示。

表 6 TCTM 速度-质量结果

配置	时间	加速比	像素多样性 σ	均值
Baseline, 无 TCTM	2.03 s	1.00x	56.4	103.9
threshold=0.3, skip=2	1.68 s	1.21x	51.1	103.5
threshold=0.5, skip=2	1.74 s	1.17x	51.1	103.5
threshold=0.5, skip=3	1.19 s	1.70x	47.2	103.4
threshold=0.7, skip=3	1.05 s	1.93x	47.2	103.4
threshold=0.7, skip=4	1.05 s	1.94x	44.5	103.5

从表 6 可见，推荐配置为 threshold=0.7、skip=3。该配置在本轮实验中达到 1.93 倍采样加速，同时均值基本稳定，说明整体像素分布没有明显偏移。其代价是像素多样性从 56.4 降至 47.2。更激进配置可以进一步提高速度，但多样性下降更明显。因此，TCTM 更适合作为推理低延迟场景的可调策略，而不是无代价质量提升方法。

7 综合结果与讨论

图 6 汇总了本轮实验的主要结果，包括 TCTM Pareto、训练曲线、SNP 多样性提升和结果表。

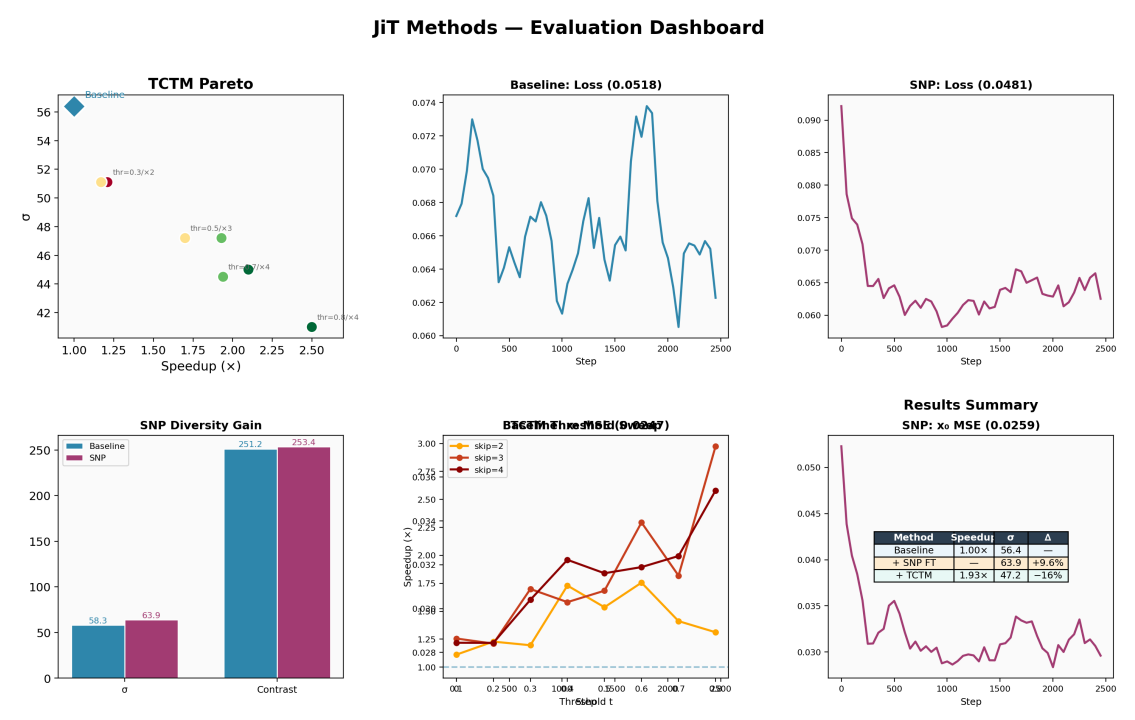


图 6 JiT 复现与改进实验总览。

三类方法的综合对比如表 7 所示。

表 7 Baseline、SNP 与 TCTM 综合对比

方法	主要目标	实验收益	主要代价
Baseline FT	复现 JiT fine-tuning 链路	稳定收敛, loss 为 0.0518	无额外改动
SNP	提高生成多样性	σ 提升 9.6%	需要额外 fine-tuning
TCTM	提高采样速度	推荐配置 1.93x 加速	多样性下降约 16%

从综合结果看，SNP 和 TCTM 改善的是两个不同维度。SNP 是训练端改进，通过结构化噪声增强模型对局部非均匀退化的适应能力，主要收益是多样性提升。TCTM 是采样端改进，通过在高噪声阶段跳步降低采样耗时，主要收益是推理速度提升。二者理论上可以叠加，但当前实验尚未在 SNP checkpoint 上系统进行 TCTM sweep，因此不能直接声称组合后能同时达到最优多样性和最优速度。

与原论文相比，本项目复现工作更强调工程链路和小规模验证。原论文使用完整 ImageNet 训练和 FID-50K 评价，并展示了 JiT 在 256、512 甚至 1024 分辨率上的扩展能力；本项目受课程资源限制，重点验证了 JiT-B/16 的核心训练采样流程，并在轻量指标上分析改进趋势。两者定位不同，因此本报告中的数值主要作为内部实验对照，而非与原论文 SOTA 结果直接比较。

8 小组分工

根据复现链路，本项目将四名成员全部分配到复现与实验工作中，分工如表 8 所示。

表 8 小组成员分工

成员	复现模块	主要职责	交付内容
全坤	模型结构复现	负责 JiT-B/16 网络结构，包括 patch embedding、Transformer block、RoPE、adaLN、in-context class tokens	模型结构代码说明、参数配置表、forward 流程图
杜承敖	训练流程复现	负责 flow matching 训练逻辑，包括 t 采样、 z_t 构造、 x_0 prediction、velocity loss、EMA、baseline fine-tuning	baseline 训练曲线、loss / x_0 MSE 结果、训练脚本说明
肖昌坤	数据与评估复现	负责 ImageNet 子集准备、数据加载、预处理、生成图像保存、proxy 指标或 FID/IS 评估流程	数据集说明、评估指标说明、baseline 采样结果
金奕辰	采样流程复现	负责 Euler / Heun ODE 采样、classifier-free guidance、采样步数和 CFG 配置复现	采样算法说明、不同采样配置对比、生成流程结果

9 局限性与后续工作

本项目仍存在以下局限性：

1. 数据规模有限。当前实验使用 ImageNet 子集，而非完整 ImageNet-1K，因此不能作为最终性能结论。
2. 指标不够完整。当前主要使用训练 loss、 x_0 MSE、像素多样性和采样时间等 proxy 指标，缺少完整 FID-50K、IS 和 precision/recall。
3. TCTM 实现简化。当前实现是 step skipping，并没有真正进行 token merging 与 restore。
4. 随机性评估不足。当前结果主要来自固定 seed 42，缺少多 seed 均值和置信区间。
5. 组合实验不足。SNP 与 TCTM 的联合收益仍需要在同一 checkpoint 和同一评估协议下验证。

后续工作可以从以下方向展开：

1. 扩大数据规模，在更大 ImageNet 子集或完整 ImageNet-1K 上重新评估。
2. 补充 FID、IS、precision/recall 等标准生成指标。

3. 对 SNP 的矩形数量、mask size、 σ_{in} 和 σ_{out} 做系统消融。
4. 在 SNP checkpoint 上重新执行 TCTM sweep，验证两者是否互补。
5. 将 TCTM 从 step skipping 升级为真正的 token merging + restore，并比较两种加速策略。
6. 对关键实验做至少 3 个 seed 的重复，给出均值和方差。

10 总结

本报告完成了 JiT 模型的核心复现和两类轻量改进实验。方法层面，我们复现了 JiT 的 x_0 prediction、flow matching loss、bottleneck patch embedding、Transformer 主干、in-context class tokens 以及 Euler/Heun 采样过程。实验层面，baseline fine-tuning 能稳定收敛，说明复现工程链路基本正确。改进层面，SNP 通过训练端结构化噪声提升了生成样本多样性，TCTM 通过采样端 step skipping 实现了接近 2 倍的推荐配置加速。

从机器学习角度看，本项目的主要收获有三点。第一，预测空间选择不仅是数学重参数化问题，在高维像素空间中还与模型容量和数据流形假设密切相关。第二，训练噪声过程的设计会影响模型看到的数据退化模式，从而影响生成多样性。第三，采样过程中的时间步分配具有明显速度-质量折中，不能只追求减少步数，还需要考虑后期细节恢复。总体而言，本项目在有限算力下完成了 JiT 的可运行复现，并给出了训练端和采样端两个可继续扩展的改进方向。

参考文献

- [1] Li T, He K. Back to Basics: Let Denoising Generative Models Denoise[J]. arXiv preprint, 2025.
- [2] Ho J, Jain A, Abbeel P. Denoising Diffusion Probabilistic Models[C]//Advances in Neural Information Processing Systems. 2020.
- [3] Lipman Y, Chen R T Q, Ben-Hamu H, et al. Flow Matching for Generative Modeling[C]//International Conference on Learning Representations. 2023.
- [4] Peebles W, Xie S. Scalable Diffusion Models with Transformers[C]//International Conference on Computer Vision. 2023.
- [5] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale[C]//International Conference on Learning Representations. 2021.
- [6] Deng J, Dong W, Socher R, et al. ImageNet: A Large-Scale Hierarchical Image Database[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2009.
- [7] Ho J, Salimans T. Classifier-Free Diffusion Guidance[J]. arXiv preprint arXiv:2207.12598, 2022.

A 附录 A 复现实验命令

Listing 4 复现实验命令

```

1  # 1. 准备 ImageNet 子集
2  bash scripts/00_download_imagenet_subset.sh
3
4  # 2. 训练 baseline
5  bash scripts/01_train_baseline.sh
6
7  # 3. 训练 SNP
8  bash scripts/02_train_snp.sh
9
10 # 4. 评估 TCTM 采样加速
11 bash scripts/03_train_tctm.sh

```

B 附录 B 关键超参数

表 9 补充超参数配置

参数	取值
label_drop_prob	0.1
P_mean	-0.8
P_std	0.8
t_eps	0.05
noise_scale	1.0
snp_mask_min	32
snp_mask_max	128
snp_noise_in	0.5
snp_noise_out	1.0
tctm_threshold	0.7
tctm_merge_ratio	0.33